

INTELIGENCIA ARTIFICIAL - PROYECTO 1

Predicción de Tarifas de Transporte en NYC

A black and white aerial photograph of the New York City skyline, showing a dense cluster of skyscrapers and buildings. The image is used as a background for the lower half of the slide.

Alina Carías, Ignacio Méndez, Ariela Mishaan y Diego Soto

Se buscó predecir el costo de un viaje en taxi

Variables del dataset (Kaggle)

- **geográficas:** longitud y latitud de pickup/dropoff
- **demográficas:** passenger_count
- **temporales:** fecha y hora de pickup



Objetivo del proyecto



Feature Engineering

Se crearon variables para mejorar rendimiento

Espaciales

- distancia en km (Haversine)

Temporales

- hora
- día de la semana
- mes
- año

Variables derivadas

- fin de semana
- rush hour

Zonas de interés

- pickup/dropoff de aeropuertos JFK, LGA, EWR

Operaciones de limpieza y preparación de datos

Se eliminaron:


- valores nulos
- tarifas ≤ 0
- tarifas muy altas (>80)
- pasajeros inválidos (0 o >6)

Filtrado geográfico

- Solo NY (latitud 40 a 42, longitud -75 a -72)




EXPLORACIÓN DE DISTRIBUCIÓN Y VARIABLES




Distribución de tarifas

Datos se concentran entre 0 y 20.
Tarifas son bastante bajas. 1572 outliers arriba de \$60.



Cantidad de pasajeros

Mayoría de viajes son de 1 o 2 pasajeros.



Ubicaciones de pickup

Alta concentración de puntos en las coordenadas de la ciudad de Nueva York, especialmente en centro.



Modelos utilizados

Comparamos 3 tipos de modelos

Regresión Lineal	KNN	Random Forest
Modelo base	Basado en vecinos cercanos	Ensemble de 100 árboles
Relaciones lineales	Usa distancia entre observaciones	Captura relaciones no lineales
n.a.	n = 7, weighs = distance	100 árboles, 15 profundidad, min sample split = 5



Resultados de los modelos


RF dio los mejores resultados

Modelo	MAE	RMSE
Regresión lineal	2.38	4.68
Random Forest	2.20	4.00
KNN	2.51	4.53

Visualización del mejor modelo

Dispersión: valores reales vs predicciones (RF).

- Concentración alrededor de la diagonal
- Buena capacidad predictiva.
- Desviaciones en valores extremos (esperado ruido y variabilidad en los datos reales).



DISCUSIÓN DE RESULTADOS



El desempeño de los modelos depende de su capacidad para capturar relaciones complejas entre variables.



El feature engineering (distancia, variables temporales, aeropuertos) mejoró significativamente el modelo.



Regresión Lineal tuvo menor desempeño debido a su suposición de linealidad.



Random Forest obtuvo el mejor rendimiento (menor MAE y RMSE), destacando en relaciones no lineales.



Se observaron mayores errores en valores extremos debido a outliers y variabilidad del dataset.



KNN mostró resultados intermedios, pero es sensible al escalado y distribución de los datos.

Pruebas de Usuario

Se implementó una función para predecir tarifas basada en:

- Coordenadas (pickup/dropoff)
- Número de pasajeros
- Fecha y hora del viaje

Se evaluaron múltiples escenarios simulados de viajes.

- ↑ Distancia → ↑ Tarifa
- Viajes cortos: \$7-\$10
- Viajes largos: hasta ~\$50
- Distancia > impacto que hora/día

Distancia (km)	Pasajeros	Hora	Día	Tarifa estimada (\$)
3.5	2	8	Lunes	14.53
4.2	1	14	Lunes	16.21
3.8	3	19	Miércoles	15.42
2.1	1	9	Jueves	10.52
12.5	2	12	Miércoles	33.26
20.0	1	16	Sábado	50.71
1.2	1	10	Jueves	7.57
5.0	4	18	Martes	18.04
3.0	2	22	Martes	13.35
1.8	1	7	martes	8.46

CONCLUSIONES

1

El modelo Random Forest obtuvo el mejor desempeño, al capturar relaciones no lineales y manejar ruido en los datos

2

El problema de predicción de tarifas requiere modelos capaces de representar relaciones complejas entre variables

3

La ingeniería de características (distancia, variables temporales, aeropuertos) fue clave para mejorar la precisión

4

El preprocesamiento de datos (limpieza y filtrado) tiene un impacto directo en el rendimiento del modelo

Recomendaciones



- Aplicar validación cruzada para mejorar la evaluación del modelo.
- Realizar un mejor ajuste de hiperparámetros (especialmente en Random Forest).
- Explorar modelos más avanzados como Gradient Boosting.
- Incorporar variables externas:
 - Tráfico
 - Clima